

Fakultet Tehničkih Nauka, Novi Sad

Rano otkrivanje Parkinsonove bolesti na osnovu glasovnih karakteristika

Autor: Danica Jovanović RA116/2023

1. Opis problema

Cilj projekta je model koji na osnovu akustičkih karakteristika glasa procenjuje da li osoba ima Parkinsonovu bolest (ciljna promenljiva status: 1 = Parkinson, 0 = zdrav). Koristi se javno dostupan [UCI Parkinson's dataset](#) — 195 snimaka glasa od 32 osobe, opisanih sa 22 numeričke karakteristike (jitter, shimmer, odnos šuma i tona, nelinearne mere frekvencije...).

Problem je rešen kao zadatak binarne klasifikacije, pri čemu je testirano više različitih algoritama uz optimizaciju njihovih hiperparametara. Za razliku od problema gde je bitnije uloviti što više pozitivnih slučajeva bez obzira na cenu (npr. marketing kampanje), ovde je greška u oba smera ozbiljna: propušten slučaj Parkinsona je loš ishod, ali i lažna dijagnoza zdravoj osobi izaziva nepotrebnu zabrinutost i dalje (nepotrebne) medicinske pretrage. Zato je kao primarna metrika korišćen F1-score, a ne čist recall.

Napomena: projekat je edukativan. Model nije medicinsko sredstvo i njegov izlaz se ne tumači kao dijagnoza.

2. Analiza i priprema podataka

Eksplorativna analiza je implementirana u **src/data_analysis.py**, detekcija anomalija u **src/anomaly_detection.py**, a centralizovano preprocesiranje (učitavanje podataka, izdvajanje atributa/ciljne promenljive i podela na trening/test skup) u **src/preprocessing.py** — ovaj modul koriste sve skripte za treniranje, kako se logika podele ne bi ponavljala na više mesta.

- Provereno je da dataset nema nedostajuće vrednosti ni duplikate redova — nije bilo potrebe za imputacijom ili čišćenjem u tom smislu.
- Svi ulazni atributi su već numerički (kontinualne akustičke mere), pa enkodiranje kategoričkih promenljivih nije potrebno — za razliku od tipičnih tabelarnih dataset-ova sa mešanim tipovima podataka.
- Atribut name (npr. phon_R01_S01_1) je uklonjen iz ulaznih atributa, jer ne nosi akustičku informaciju o glasu. Umesto da se odbaci u potpunosti, iz njega je izvučen identifikator osobe (S01), koji je iskorišćen kao groups parametar za podelu podataka — ovo se pokazalo kao ključna odluka projekta (videti dalje).
- Svi modeli se treniraju kroz Pipeline sa StandardScaler-om (z-score standardizacija), neophodnom za modele osetljive na skalu i rastojanje (KNN, SVM, logistička regresija).

2.1 Podela na trening i test skup


`preprocessing.split_data` deli podatke na trening (80%) i test (20%) skup na nivou **subjekta** (osobe), ne na nivou pojedinačnog snimka: prvo se izdvoje jedinstveni subjekti i njihov status, pa se `train_test_split` (stratifikovano po statusu) primeni nad subjektima, a zatim se maska subjekata mapira nazad na sve njihove snimke. Time je garantovano da nijedna osoba ne završi istovremeno i u trening i u test skupu (0 preklapanja subjekata, provereno u `preprocessing.main()`) — bez ovoga bi obična podela na nivou snimka skoro

sigurno pomešala snimke iste osobe u oba skupa, što bi izazvalo curenje podataka na nivou subjekta.

Poseban validation skup nije izdvojen, jer dataset ima samo 32 osobe — premalo da bi se dalje delio na tri skupa bez previsoke varijanse. Umesto toga, validacija modela, izbor atributa i podešavanje hiperparametara se rade pomoću **5-fold Group Cross Validation** na trening skupu (poglavlje 3). `random_state` podele je parametrizovan (a ne fiksiran), da bi se u `src/split_robustness.py` mogla proveriti osetljivost rezultata na konkretan izbor split-a (poglavlje 5.4).

2.2 Raspodela klasa

147 snimaka pripada klasi Parkinson, a samo 48 klasi zdrav — odnos otprilike 3:1. Ovaj disbalans nije ekstremn kao kod nekih realnih problema (npr. detekcija prevara), ali je dovoljan da naivno treniran model favorizuje većinsku klasu, pa je direktno uticao na izbor metrike i hiperparametara modela (poglavlje 6).




Raspodela klasa u dataset-u (Parkinson vs. zdrav)

2.3 Korelacije među atributima

Korelaciona matrica pokazuje da su atributi izvedeni iz istog fizičkog fenomena međusobno snažno korelisani — npr. `MDVP:Jitter(%)`, `MDVP:RAP`, `MDVP:PPQ` i `Jitter:DDP` sve mere variraju oko istog svojstva glasa (jitter — nestabilnost frekvencije), a slično vredi za grupu `Shimmer:APQ3/APQ5`, `MDVP:APQ`, `Shimmer:DDA` (shimmer — nestabilnost amplitude). Ova multikolinearnost nije uklonjena ručnim brisanjem kolona (kao što bi se uradilo kod, recimo, ekonomskih indikatora), već je rešena sistematičnije — kroz odabir atributa na osnovu njihove važnosti za model (poglavlje 5), koji prirodno favorizuje jednog predstavnika iz svake korelisane grupe.


Raspodela top-9 atributa po klasi (boxplot)



Raspodela vrednosti top-9 atributa (histogram)

2.5 Anomalije

Pored vizuelne provere boxplot-ovima, u `src/anomaly_detection.py` su primenjene tri nenadgledane metode detekcije anomalija nad standardizovanim atributima: **KNN** (rastojanje do K-tog najbližeg suseda), **Local Outlier Factor** (lokalna gustina okoline tačke) i **Isolation Forest** (broj podela potrebnih da se tačka izoluje). Svaka metoda nezavisno predlaže top-10 najsumnjivijih snimaka; presek sve tri metode — jači signal nego slaganje samo jedne — su 4 snimka, sve od osoba S24 i S35.




Bitan detalj: anomalna su samo 4 od ukupno 13 snimaka ove dve osobe (S24 ima 6 snimaka, S35 ima 7) — ne svi njihovi snimci. Da je cela osoba "čudna", to bi ukazivalo na grešku u opremi ili protokolu snimanja za tu osobu; pošto su samo pojedini njeni snimci izolovani, to više liči na prirodnu varijaciju izraženosti simptoma iz snimka u snimak, nego na grešku u merenju.

Odluka da se ovi snimci ne uklone je i empirijski provarena: treniranje istog modela bez ta 4 snimka **pogoršava** i CV F1 (0.871 → 0.848) i test ROC-AUC (0.970 → 0.938), bez ikakve dobiti na ostalim test metrikama. Uklanjanje ovde ne čisti šum — briše deo signala koji model treba da nauči, jer je skup već mali (195 redova, 32 osobe) i ne može se rizikovati taj gubitak.

2.6 PCA vizualizacija

2D projekcija svih 22 atributa (PC1 = 58.9%, PC2 = 11.3% varijanse, ukupno $\approx 70\%$) pokazuje delimično preklapanje klasa duž glavnih komponenti. To znači da problem nije trivijalno linearno razdvojiv u 2D prostoru — informativan je signal da treba isprobati i nelinearne modele (Random Forest, Gradient Boosting), a ne osloniti se samo na logističku regresiju.



PCA projekcija (PC1 vs PC2), obojena po klasi

3. Odabir i treniranje modela

Svi modeli su trenirani u skripti **src/train.py**. Isprobano je šest algoritama pogodnih za binarnu klasifikaciju na malom tabelarnom skupu: logistička regresija, KNN, SVM, stablo


odlučivanja, Random Forest i Gradient Boosting (XGBoost), uz **baseline** model (DummyClassifier, uvek predviđa većinsku klasu) kao donju referentnu granicu. Svaki model je evaluiran pomoću **5-fold Group Cross Validation** (StratifiedGroupKFold) na trening skupu.

Zašto grupna (group) cross-validacija, a ne obična stratifikovana?


Dataset ima 195 snimaka od samo 32 osobe, sa po nekoliko snimaka po osobi i istim statusom za sve snimke jedne osobe. Obična podela na nivou snimka bi gotovo sigurno stavila snimke iste osobe i u trening i u validacioni/test fold, čime bi model delom učio da prepoznaje konkretnu osobu po glasu umesto generalizovanog biomarkera bolesti — ovo se naziva curenje podataka na nivou subjekta. Zato se i podela na trening/test skup (80/20) i sva cross-validacija (poređenje modela, odabir atributa, tuning hiperparametara) rade grupisano po osobi, koristeći identifikator izvučen iz kolone name u poglavlju 2.

3.1 Rezultati poređenja (5-fold group CV, prosek)

Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
Baseline (majority class)	0.764	0.764	1.000	0.864	0.500
SVM	0.856	0.859	0.992	0.914	0.704
Random Forest	0.803	0.837	0.951	0.881	0.769
Gradient Boosting (XGBoost)	0.763	0.826	0.909	0.855	0.791
Logistic Regression	0.796	0.871	0.901	0.872	0.755
KNN	0.744	0.823	0.885	0.840	0.796
Decision Tree	0.731	0.835	0.844	0.827	0.647



Poređenje performansi modela po metrikama



Raspon F1-score-a po fold-u (5-fold group CV) — bitan prikaz uz samo 195 uzoraka, gde varijansa po fold-u nije zanemarljiva

Baseline ima $F1 = 0.864$ uprkos tome što ne razlikuje klase nikako — posledica neravnomernih klasa (*accuracy paradox*): kada jedna klasa dominira, model koji uvek predviđa tu klasu izgleda dobro po $F1$ /accuracy, samo zato što se retko greši na većinskoj klasi. ROC-AUC = 0.5 to razotkriva (model bez ikakve prediktivne moći nužno ima ROC-AUC = 0.5), zato je svaki model u tabeli ocenjivan i po ROC-AUC, ne samo po $F1$ /accuracy. Po tom kriterijumu, svi modeli osim Decision Tree-a jasno nadmašuju baseline.

3.2 SVM

SVM postiže najviši $F1$ (0.914) i recall (0.992) među svim modelima — granica odlučivanja sa RBF jezgrom uspeva da uhvati skoro sve slučajeve Parkinsona. Problem je ROC-AUC od samo 0.704, najslabiji od preostalih ozbiljnih modela — to znači da SVM dobro klasifikuje na podrazumevanom pragu (0.5), ali loše rangira svoje verovatnoće kada se taj prag pomera. Pošto se u poglavlju 6 threshold posebno bira preko ROC krive, model koji loše rangira verovatnoće gubi tu prednost — pa SVM, uprkos najboljem $F1$ ovde, nije dobar kandidat za finalni model.

3.3 Random Forest

Drugo najbolje $F1$ (0.881) i najbolji ROC-AUC (0.769) među modelima koji imaju i solidan $F1$. Prirodno daje feature importance, što je direktno korisno za odabir atributa u poglavlju 5. Takođe je otporan na multikolinearnost uočenu u EDA (poglavlje 2.3) — bagging usrednjava više stabala treniranih na nasumičnim podskupovima atributa, pa korelisani atributi ne narušavaju stabilnost modela kao kod logističke regresije. Iz ovih razloga je Random Forest izabran kao finalni model.

3.4 Logistic Regression

Najbolja preciznost (0.871) među top modelima — kada proglaši Parkinson, retko se vara. ROC-AUC od 0.755 je solidan, ali niži od Random Forest-a. Kao linearan model, osjetljiviji je na multikolinearnost iz poglavlja 2.2 nego stablo zasnovani modeli — koeficijenti korelisanih atributa mogu biti nestabilni (veliki, suprotnog znaka), iako to ne mora vidljivo pogoditi same predikcije.

3.5 Gradient Boosting (XGBoost)


Najviši ROC-AUC (0.791) od svih modela — najbolje rangira verovatnoće, što bi ga činilo privlačnim kandidatom za biranje threshold-a. Međutim, na default hiperparametrima ima niži F1 (0.855) od SVM/RF/LogReg, jer u ovoj fazi hiperparametri nisu posebno podešavani za XGBoost. Da je projekat imao više vremena za tuning, ovo bi bio prirodan drugi kandidat za finalni model.

3.6 KNN i Decision Tree


KNN ima ROC-AUC = 0.796 (drugi najbolji), ali nizak F1 (0.840) — osjetljiv je na neravnomerne klase, jer K najbližih susjeda lakše budu iz većinske klase. Decision Tree ima najslabiji ROC-AUC (0.647) od svih ozbiljnih modela i najslabiji F1 — jedno stablo bez ansambla je sklono overfitting-u na ovako malom skupu (32 osobe), pa loše generalizuje na nove osobe.

4. Odabir najznačajnijih atributa

Implementirano u **src/feature_selection.py**. Značajnost atributa je računata pomoću `feature_importances_` iz Random Forest-a, a zatim su atributi rangirani i testirani u podskupovima rastuće veličine (1, 2, ..., svih 22), svaki put sa istim 5-fold group CV protokolom kao u poglavlju 3.



Značajnost atributa prema Random Forest-u



Performanse modela u zavisnosti od broja korišćenih atributa

Najbolji rezultat (po F1, zatim recall-u, zatim ROC-AUC) postiže podskup od **10 atributa**: PPE, MDVP:Flo(Hz), spread1, MDVP:Fo(Hz), MDVP:Fhi(Hz), NHR, RPDE, Jitter:DDP, MDVP:jitter(Abs), spread2 — F1 = 0.896, recall = 0.959, ROC-AUC = 0.804, naspram F1 = 0.881 sa svih 22 atributa.

Zaključak: korišćenje samo 10 najbitnijih atributa ne pogoršava model — naprotiv, blago ga poboljšava i smanjuje rizik od overfitting-a na ovom malom skupu (manje parametara/podela

po manjem broju dimenzija znači manju šansu da model "pamti" specifičnosti trening skupa). Ovih 10 atributa je korišćeno u finalnom modelu.


5. Podešavanje hiperparametara, finalni model i evaluacija

Implementirano u **src/final_model.py**. Hiperparametri Random Forest-a su podešeni pomoću GridSearchCV (5-fold group CV, scoring = F1) nad gridom za `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf`.

5.1 Finalni model — podešavanje hiperparametara

Najbolja kombinacija hiperparametara pronađena pretragom (`GridSearchCV.best_params_`):

Hiperparametar	Vrednost
<code>n_estimators</code>	100
<code>max_depth</code>	None
<code>min_samples_split</code>	5
<code>min_samples_leaf</code>	2
Best CV F1-score	0.871



F1-score za kombinacije $n_estimators \times max_depth$

Finalni model je dakle: `Pipeline(StandardScaler, RandomForestClassifier(n_estimators=100, max_depth=None, min_samples_split=5, min_samples_leaf=2, class_weight="balanced"))`, treniran nad 10 atributa izabranih u poglavlju 4, sa decision threshold-om biranim u poglavlju 5.2.

5.2 Dve dodatne odluke


Pored standardnog GridSearch-a, doneta su dva dodatna podešavanja, motivisana zapažanjima iz EDA i prirodom medicinskog problema:

- **class_weight="balanced"** — zbog neravnomernih klasa (147 vs 48), bez ovog podešavanja model favorizuje većinsku (Parkinson) klasu i ima tendenciju da skoro sve proglasi pozitivnim.
- **Decision threshold** se ne uzima podrazumevano kao 0.5, već se bira preko ROC krive i Youden indeksa, isključivo na osnovu out-of-fold predikcija na trening skupu (cross_val_predict, grupisano po osobi) — nikad na test skupu, kako test labele ne bi "iscurele" u izbor modela. Izabrani threshold: **0.769**.


5.3 Evaluacija — rezultati na test skupu

Evaluacija je implementirana u **src/evaluate.py**, koja učitava sačuvani finalni model (models/best_model.joblib) i prijavljuje metrike isključivo na test skupu (7 osoba, 43 snimka), koji nikada nije korišćen tokom selekcije modela, hiperparametara ili threshold-a:


Metrika	Vrednost
Best CV F1-score	0.871
Decision threshold	0.769
Accuracy	0.930
Precision	0.912
Recall	1.000
F1-score	0.954
ROC-AUC	0.970
Average Precision	0.989



Matrica konfuzije na test skupu



ROC kriva — ponašanje modela kroz različite pragove odlučivanja




Precision-Recall kriva

5.4 Diskusija i ograničenja

Recall od 100% na test skupu znači da model nije propustio nijedan slučaj Parkinsona u testu — za ovaj tip problema to je poželjno, jer je propušten pozitivan slučaj gore od lažnog alarma. Test skup ima, međutim, samo 7 osoba — jedna pogrešno klasifikovana osoba bi promenila metrike za desetak procentnih poena, pa su ove vrednosti procena sa visokom varijansom, ne konačna istina o kvalitetu modela.

Da bi se ta varijansa kvantifikovala, **src/split_robustness.py** ponavlja čitav postupak (podela → trening → evaluacija) za 7 različitih `random_state` vrednosti pri podeli na osobe. Accuracy se kreće 0.67–0.88 (prosek ≈ 0.78 , std ≈ 0.09), a F1-macro 0.40–0.83 — raspon koji potvrđuje da je tačkasta procena na jednom test skupu samo deo slike, i da je pouzdaniji uvid u kvalitet modela 5-fold group CV rezultat iz poglavlja 3/4 (Best CV F1-score = 0.871).



Robustnost metrika na izbor train/test split-a (7 random seed-ova)

Bias-variance / over-underfitting

`src/learning_curve.py` upoređuje train i CV F1-score finalnog modela u zavisnosti od veličine trening skupa. Rezultat je sačuvan kao tabela, ne grafik — sa samo 32 osobe, svaka tačka je CV procena na grupama od ~5-6 osoba po fold-u (CV F1 std. devijacija po veličini je 0.05-0.07, istog reda veličine kao razlike između susednih tačaka), pa bi glatka linija na grafiku sugerisala čistiji trend nego što ovaj dataset stvarno može pokazati.

Train F1 brzo dostiže ~0.99 (već sa 31 uzorkom), dok se CV F1 kreće 0.84–0.88 kroz čitav opseg veličina, sa blagim padom na najveće dve veličine (0.846, 0.844 na 139/158 uzoraka). Razmak od ~0.10-0.15 kroz ceo opseg je znak blagog overfitting-a, očekivanog kod Random Forest-a (bagging) na ovoliko malom skupu. Bitno je da razmak postoji kroz ceo opseg veličina, ne samo na najvećoj — to je znak da je strukturna karakteristika modela na ovom dataset-u, ne nedostatak podataka koji bi nestao samo postepenim dodavanjem uzoraka iz **istog**, već postojećeg skupa od 32 osobe.

Probano je i sa jačom regularizacijom (manji `max_depth`, veći `min_samples_leaf`): razmak se ne smanjuje značajno (0.125 → 0.108), dok CV F1 pada (0.871 → 0.818). Kod bagging metoda kao Random Forest, razmak delom dolazi iz same prirode bagginga (svako stablo skoro savršeno klasifikuje sopstveni bootstrap uzorak), pa ga je teško ukloniti bez žrtvovanja generalizacije.

6. Deployment modela

Finalni Pipeline (StandardScaler + RandomForest), lista izabranih atributa i decision threshold se čuvaju pomoću joblib biblioteke u:

- `models/best_model.joblib`
- `models/selected_features.joblib`
- `models/decision_threshold.joblib`

src/predict.py centralizuje učitavanje ovih artefakata i logiku predikcije (`predict_from_features`), da se ne ponavlja na više mesta u kodu.

app/ui.py je Streamlit forma za unos glasovnih biomarkera, koja prikazuje predikciju i procenju verovatnoću, koristeći isti `predict.py` modul i iste sačuvane artefakte:

```
streamlit run app/ui.py
```

7. Zaključak

Finalno rešenje — Random Forest sa 10 izabranih atributa, balansiranim klasama i pažljivo (cross-validacijom na trening skupu) biranim decision threshold-om — daje F1-score od ~0.87–0.95 (CV / test), uz recall od 100% na test skupu. To je poželjan ishod za ovaj tip problema, jer je propušten pozitivan slučaj klinički gore od lažnog alarma.

Tri metodološke odluke su imale najveći uticaj na pouzdanost rezultata:

- grupna podela po subjektu (`StratifiedGroupKFold`) — sprečava curenje podataka na nivou osobe, koje bi inače veštački naduvalo metrike;
- `class_weight="balanced"` — sprečava da model samo predviđa većinsku klasu zbog disbalansa 147/48;
- biranje threshold-a isključivo na trening podacima (out-of-fold predikcije) — sprečava curenje test labela u proces selekcije modela.

Glavno ograničenje projekta je veličina dataset-a — samo 32 osobe. Zbog toga svaka tačkasta metrika u ovom dokumentu nije prikazana izolovano, već je praćena merom svoje varijanse: rasponom po fold-u u cross-validaciji i robusnošću na izbor train/test split-a (poglavlje 5.4). Ima prostora za napredak — pre svega prikupljanje podataka od više osoba, što bi smanjilo varijansu svih prikazanih metrika i omogućilo pouzdaniju procenu generalizacije na potpuno nove pacijente.